Come lavora il modello — visione d’insieme

Spiegazione didattica · senza jargon · flusso completo fino alla BI

PASSO 1 — Guardiamo il passato

Dati grezzi → “foto” del negozio × articolo a una data (as_of)

Vendite recenti, giacenza, sconti, meteo, festivi, età del prodotto…
Queste informazioni si chiamano FEATURE. Non sono ancora la previsione.

PASSO 2 — Due “cervelli” leggono le stesse foto (orizzonte 15 giorni)

LightGBM

Impara regole da migliaia di esempi
“Se run-rate alto e sconto → di più”
Veloce e bravo sui pattern tabellari
Dà una stima in pezzi

Rete neurale Dual-head (TF)

Altro modo di leggere le stesse info
Due uscite: SKU e categoria
Parte dal run-rate e lo corregge
Dà una seconda stima in pezzi

PASSO 3 — Un “regista” sceglie / mescola le stime

Routing + confidence (ensemble)

Confronta le stime, corregge i casi strani, applica regole operative
Risultato: UNA previsione a 15 giorni (e p80 più cauta)

PASSO 4 — Orizzonti più lunghi (modelli dedicati)

h30 nativo

Modello a 1 mese
stesse feature
target = venduto 30g

h60 nativo

Modello a 2 mesi
stesse feature
target = venduto 60g

h90 nativo

Modello a 3 mesi
stesse feature
target = venduto 90g

PASSO 5 — Output umano

BI CDM · quantità da riassortire · report

Previsione pezzi 15g / 1m / 2m / 3m per negozio e modtescol
Qty = pezzi da mandare (previsione – giacenza, con regole cautela)
Storico: confronto previsto vs venduto reale sulla forbice scelta

Idea chiave: non c’è un solo algoritmo. Feature → più modelli → mix → numeri per CDM.

Struttura a layer — Dual-head TensorFlow

Come è fatta la rete neurale (semplificata ma fedele al codice)

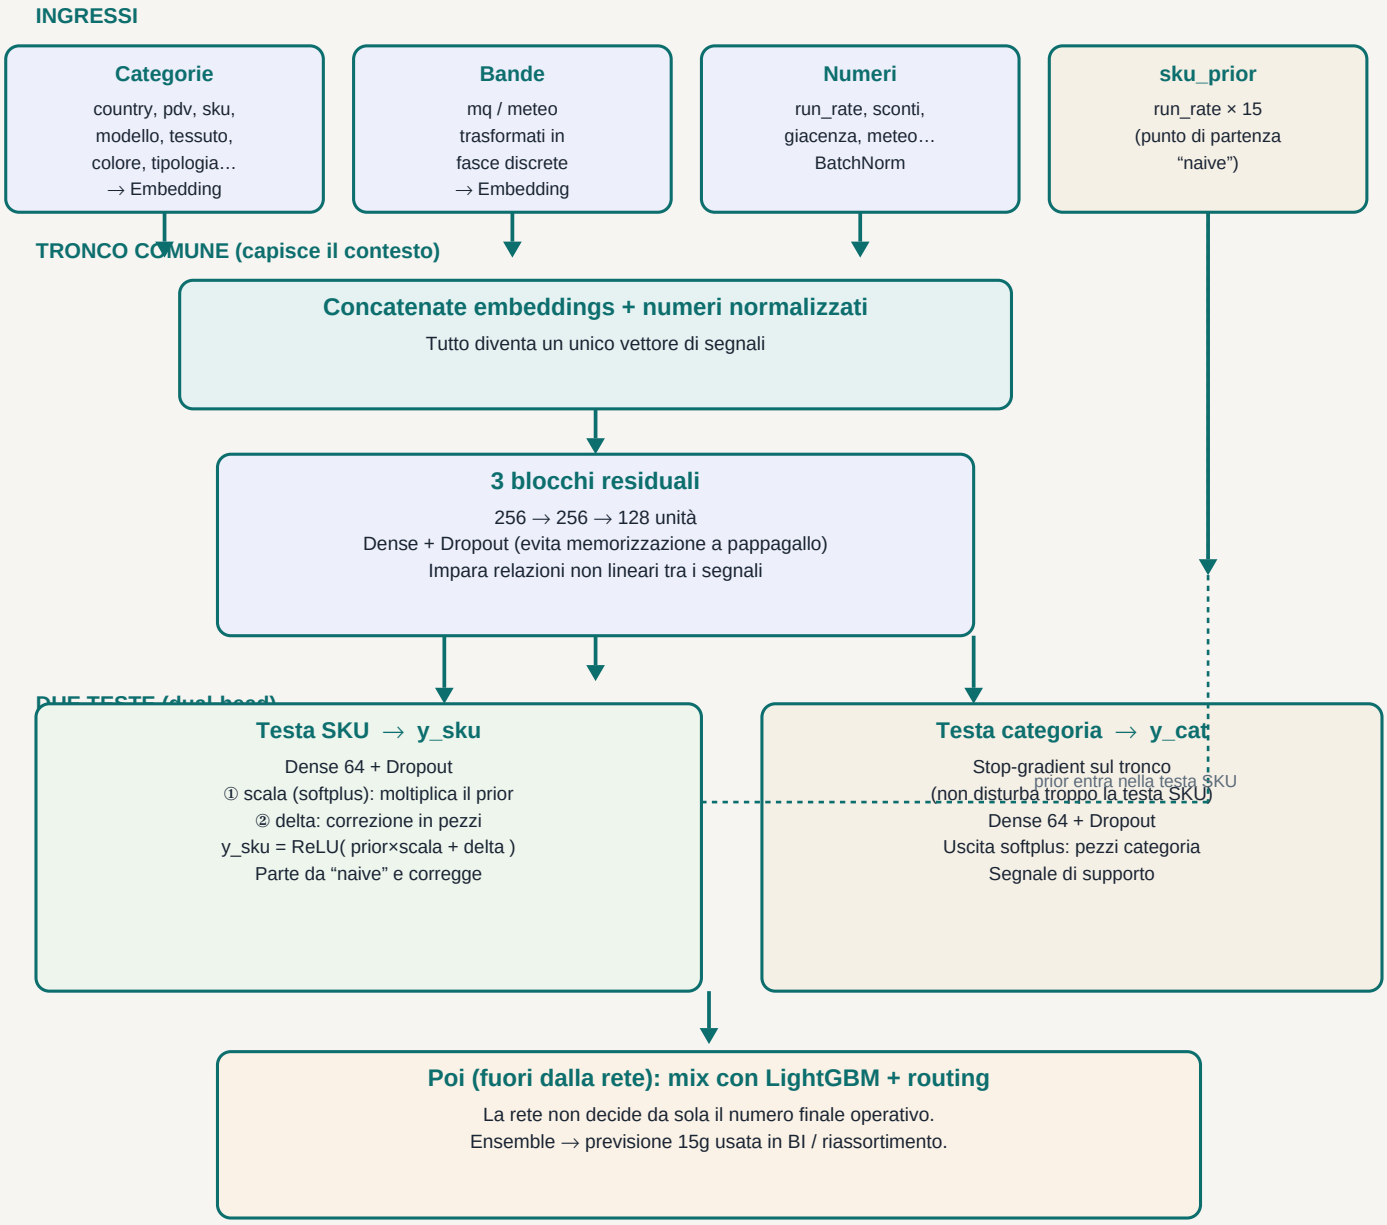

Analogia: il tronco "capisce la situazione"; la testa SKU corregge il run-rate; la testa categoria dà contesto.

LightGBM, artifacts e lettura del flusso

Gli altri pezzi del sistema, in linguaggio semplice

LIGHTGBM (idea)

Tante regole piccole messe in sequenza

Ogni “albero” corregge un po’ l’errore del precedente
Input = stesse feature numeriche/categoriche della foto as_of
Output = pezzi previsti (15g, oppure 30/60/90 nei modelli nativi)

ARTIFACTS (cosa resta dopo l’addestramento)

File pronti all’uso (non si riaddestra ogni volta)

dual_head.keras · encoders → rete TF
lgbm_*_bundle.joblib · maps → LightGBM 15g
h30/h60/h90/lgbm_bundle.joblib → orizzonti lunghi
samples.pkl → foto storiche usate per train e holdout

FLUSSO MENTALE IN 1 RIGA

Dati → Feature (as_of) → Modelli (LGBM + Dual-head + h30/60/90) → Mix → BI

Addestrare = aggiornare gli artifacts · Inferire = usarli per prevedere

COSA NON FA IL MODELLO

Limiti (utili da ricordare in review CDM)

Non “capisce” il brand: imita correlazioni dello storico
SKU nuovissimi = meno affidabili (poca storia)
as_of on-demand ok, ma più incerto se il giorno è atipico