Report tecnico — Modello Forecast Riassortimento

Progetto **modello-forecast** · Dati Valido reali · Aggiornato 2026-09-18

Documento di sintesi su architettura del modello, scelte progettuali, pipeline dati, modifiche recenti e risultati del primo training pilota su dati reali (export Valido → fact_daily → DualHead TensorFlow + challenger LightGBM).

1. Obiettivo e perimetro

Prevedere la **domanda attesa a 15 giorni** per ogni coppia PDV×SKU e proporre una **quantità di riassortimento** a supporto del team CDM. Lo strumento è interno: review umana obbligatoria, nessun ordine automatico a Produzione. La baseline ufficiale da battere è il sistema a regole CDM (non solo il naive run-rate).

Vincoli di governance: isolation testing/production; split temporale (no shuffle random sugli as_of); nessun tag stagione ESTATE/INVERNO in input; su Mac sempre `OMP_NUM_THREADS=1` e training su CPU.

2. Struttura del modello

2.1 Pipeline end-to-end

```
Valido export24kk.csv
   ■  tipodoc 100 = vendite; 47/51/20 = stock (giacenza)
   ▼
fact_daily.csv  (giorno × PDV × SKU)
   + products.csv (DNA SKU) + pdv_master.csv + calendar
   ▼
Sample rolling (as_of ogni 14gg): feature 7/14/28 + target y_sku 15gg
   ▼
DualHead TensorFlow  →  blend confidence/analoghi  →  qty operativa
        ▲
LightGBM challenger (stesso split) + routing per fascia di volume
```

2.2 Target

y_sku = somma di `vendite_qty` nell'intervallo (as_of, as_of+15 giorni]. **y_cat** (ausiliario) = aggregato per PDV×categoria, con loss su log1p. La rete impara soprattutto y_sku; la testa categoria regolarizza il trunk senza backprop diretto dal ramo cat sul representation condiviso (stop-gradient).

2.3 Architettura DualHead (TensorFlow/Keras)

Implementazione di riferimento: `testing/model/dual_head_tf.py`. Il training reale riusa questa architettura via `production/run_train_real.py`.

Blocco	Dettaglio
Input categorici	Embedding: country, pdv_id, sku_id, categoria_id, commerciale, modello, tessuto, colore, campagna, classe, sclasse, ssclasse, tipologia
Input numerici	~57 feature (run-rate 7/14/28, trend, stock, sconto, mq, meteo, cold start, calendario, profilo meteo-SKU) + BatchNorm
sku_prior	max(run_rate_14d × 15, 0.05) — ancora naive verso cui la rete scala
Trunk	Blocchi residuali Dense 256→256→128, dropout 0.15/0.15/0.10
Head SKU	y = ReLU(sku_prior × softplus(scale) + delta); init ≈ naive
Head CAT	stop_gradient(trunk) → Dense → softplus; target log1p(y_cat)
Loss	Huber(y_sku, δ=5)×1.0 + Huber(y_cat, δ=1)×0.15
Ottimizzazione	Adam + CosineDecay; early stopping su val MAE SKU
UNK	Indice 0 per entità mai viste; UNK dropout 2% in train

2.4 Layer post-modello e operativo

Dopo la rete: **confidence score** e blend con analoghi per SKU/PDV giovani. Qty suggerita: daily = forecast/15; need = forecast + daily×transit; raw = max(0, need − giacenza) × clip(0.45+0.55×confidence, 0.45, 1); qty = round(raw). Azione: *monitora* se qty=0, altrimenti *valuta_riassortimento*.

3. Dati reali Valido

3.1 Ingest

Script: `production/run_ingest_export.py`. Fonte: export Valido (~24M righe). Regole tipodocumento: **100**=vendita (domanda); **47** e **51**=carico; **20**=azzeramento. La colonna **giacenza** esiste già nell'export (campo 10); in fact_daily diventa `giacenza_qty` (ultima del giorno). Valori negativi (~5%) sono rumore Valido: in training vengono clippati a ≥0 per le feature operative.

Output principale: `data/real/fact_daily.csv` (~20,4M righe, 165 PDV, ~23k SKU, date 2024-01-01 → 2026-08-18).

3.2 Master PDV e DNA SKU

PDV: merge da `Info_negozi.xlsx` su `pdv_master.csv` (mq/città/formato). Restano ~42 PDV parziali. **SKU:** file `DNA SKU.xlsx`. I fogli VENDITE/RIDOTTO erano nascosti; usati **solo per attributi**, mai per sostituire le vendite di fact_daily. Struttura codice Valido: ModTes(7)+Taglia(3)+Colore(3). Tessuto ≈ caratteri 6–7 del modello agganciati a INFO TESSUTO (~89% coverage). Campagna/classe da RIDOTTO solo PE_26/AI_26 (~32% SKU con DNA ricco); il resto ha NA esplicito.

4. Scelte progettuali chiave

Scelta	Motivazione
Domanda attesa ≠ vendite certe	Allineamento meeting CDM: supporto decisionale, non automa ordini
Dual-head + sku_prior	Init vicino al naive; la rete impara correzioni (meteo/promo/cold start)
No tag stagione in input	In Valido non c'è; stagione appresa da calendario + temp + sku_weather
Tenere campagna/classe con NA	Non droppare per uniformità: utile dove c'è DNA; missing = categoria nota
Vendite solo da fact_daily	RIDOTTO/DNA non è fonte domanda; evita leakage e doppio conteggio
Pilota 40 PDV prima del full	Runtime/memoria: fact 2.6GB; validare pipeline prima del train rete intera
LightGBM come challenger	Stesso split; feature importance; verifica che TF non sia solo overfit
Routing per prior di volume	Sulla coda y>15 TF/LGBM peggioravano il naive → regole causali su run-rate
Repo GitHub senza fact_daily	File troppo pesante; codice+master sì, dataset su copia locale/VM

5. Modifiche effettuate in questa fase

5.1 Dati e contratti

• Confermato tipodoc 51 = carico women; tipodoc giacenza = 100+47+51+20.

• Ingest streaming CSV (evita OOM su DataFrame monolitico).

• Aggiornamento pdv_master da Info negozi (backup stub conservato).

• Arricchimento products.csv da DNA: modello/colore/taglia per tutti; tessuto ~89%; campagna/classe/nome ~32% via RIDOTTO nascosto.

• Calendario reale espanso (mese, sin/cos anno, festivi/saldi) in calendar_full.

5.2 Codice training / evaluation

• `production/run_train_real.py` — training DualHead su data/real (pilota FORECAST_PILOT=1 o full).

• `production/run_challenger_real.py` — TF vs LightGBM + metriche per fascia.

• Fix Lambda stop-gradient nominata in dual_head_tf (deserialize più sicuro).

• Giacenza clip ≥0 in feature train; DNA sovrascritto sull'ingest stub.

• Ensemble routing prior-based salvato in ensemble_routing_metrics.json.

6. Risultati sperimentali (pilota reale)

Ambito pilota: top 40 PDV per volume, as_of ogni 14 giorni da 2025-10-01 a 2026-07-22, holdout temporale test as_of ≥ 2026-06-24. Sample ~835k righe (train ~692k, test ~142k).

6.1 Metriche globali test

Modello	MAE	wMAPE %	MAPE %	R^2
naive	3.725	51.3	96.4	0.932
cdm	4.312	59.4	103.4	0.844
tf_raw	3.523	48.5	74.0	0.871
tf_blend	3.510	48.4	73.8	0.871
lgbm_raw	3.571	49.2	64.9	0.860
lgbm_blend	3.526	48.6	66.0	0.861

Modello	MAE	wMAPE %	MAPE %	R^2
route_mix	3.404	46.9	75.9	0.923
route_naive_high	3.466	47.8	77.9	0.932

Interpretazione: la mediana di y_sku sul test è ~4 pezzi/15gg; un MAE ~3.5 resta operativamente alto. TF e LGBM battono CDM/naive in aggregato, ma sulla coda **y>15** entrambi peggiorano il naive (~19 vs ~15 MAE): da qui la regola di routing.

6.2 Metriche per fascia di volume (sintesi)

Fascia	mean y	Naive MAE	TF MAE	LGBM MAE	Nota
y (0,2]	1.5	1.93	1.31	1.08	LGBM migliore
y (2,5]	3.8	2.48	1.57	1.76	TF migliore
y (5,15]	8.9	4.56	4.47	4.69	margine piccolo
y >15	47.8	15.1	19.5	19.4	Meglio il naive

6.3 Routing ensemble (prior = run_rate_14d×15)

Regola causale (senza usare y futuro): prior≤3 → LGBM; prior in (3,15] → TF; prior>15 → naive (variante `route_naive_high`) oppure mix 0.35·TF+0.65·naive. Winner globale: **route_mix**.

Variante	MAE	wMAPE %
tf_blend	3.510	48.4
lgbm_blend	3.526	48.6
route_mix	3.404	46.9
route_naive_high	3.466	47.8
naive	3.725	51.3

6.4 Feature importance LightGBM (top)

Feature	Importance
sku_id	33838
modello	13981
pdv_id	6274
tessuto	1747
colore	1099
pdv_age_days	578
trend_14v28	575
temp_media	557
cos_anno	537
giacenza	532

Dominano identità (sku_id, pdv_id) e DNA (modello, tessuto, colore): conferma che completare il catalogo ha valore, soprattutto per cold start e analoghi.

7. Artefatti e file chiave

Path	Ruolo
data/real/fact_daily.csv	Vendite/giacenza giornaliere Valido
data/real/products.csv	DNA SKU arricchito
data/real/pdv_master.csv	Anagrafica negozi
data/manual/DNA_SKU.xlsx	Fonte DNA (fogli nascosti inclusa)
production/run_ingest_export.py	Ingest export → fact_daily
production/run_train_real.py	Training DualHead su dati reali
production/run_challenger_real.py	TF vs LightGBM + fasce
testing/model/dual_head_tf.py	Architettura rete (SoT)
production/artifacts/real/	Modelli, metriche, sample pilota
docs/DATA_CONTRACTS.md	Contratti dati riunione

8. Prossimi passi consigliati

• Training full rete (tutti i PDV) con routing in inferenza.

• Meteo Open-Meteo reale al posto del profilo mensile.

• DNA SKU oltre PE/AI 26; chiusura PDV stub.

• Winsorize outlier estremi in train; metriche ufficiali = MAE per fascia + wMAPE.

• Porting inferenza CDM 15gg in production.pipeline con export reviewabile.

Fine report. Metriche numeriche riprese dagli JSON in `production/artifacts/real/`.